

1. Gợi ý Tên Đề Tài (Project Titles)

♦ Phương án 1: Chuẩn học thuật / Báo cáo khoa học

KHUYẾN NGHỊ

Tiếng Việt: Xây dựng Pipeline Học Máy Đa Mô Hình Hỗ Trợ Học Từ Vựng Tiếng Anh Phân Cấp Theo Khung Trình Độ CEFR (A1–C1) Từ Đầu Vào Tiếng Việt

Tiếng Anh: A Multi-Model Machine Learning Pipeline for CEFR-Leveled English Vocabulary Learning and Controlled Example Generation from Vietnamese Inputs

♦ Phương án 2: Tập trung kỹ thuật NLP & Controlled Generation

Tiếng Việt: Hệ Thống Dịch Thuật Ngữ Nghĩa, Phân Loại Độ Khó CEFR và Sinh Câu Ví Dụ Có Ràng Buộc Trình Độ Dành Cho Người Học Tiếng Anh

Tiếng Anh: Semantic Translation, CEFR Complexity Classification, and Controlled Sentence Generation for English Language Learners

♦ Phương án 3: Hướng ứng dụng & Sản phẩm (CapyVocab Ecosystem)

Tiếng Việt: CapyVocab ML: Hệ Thống Học Máy Thông Minh Cá Nhân Hóa Từ Vựng Tiếng Anh Theo Trình Độ CEFR

Tiếng Anh: CapyVocab ML: An Intelligent Multi-Stage Machine Learning System for Personalized English Vocabulary Acquisition

2. Bản Mô Tả Tổng Quan Về Đề Tài (Project Overview)

2.1. Đặt vấn đề & Động lực (Motivation)

Trong quá trình học tiếng Anh, người học (đặc biệt là người Việt) thường gặp phải các rào cản lớn:

- Lệch chuẩn trình độ:** Tra cứu từ tiếng Việt nhưng nhận về từ tiếng Anh không tương thích với trình độ bản thân (quá cơ bản hoặc quá hàn lâm/học thuật).
- Thiếu câu ví dụ kiểm soát theo năng lực:** Thiếu các câu mẫu vừa chứa đúng từ mới, vừa chuẩn ngữ pháp và vừa vặn với trình độ đọc hiểu (CEFR A1–C1) đang rèn luyện.
- Hạn chế của dịch máy thông thường:** Các công cụ dịch chỉ chuyển ngữ bề mặt, không có khả năng phân cấp độ khó hay thẩm định chất lượng ngôn ngữ.

Giải pháp: Đề tài **CapyVocab ML** xây dựng hệ thống học máy nhiều tầng (End-to-End Multi-Model Pipeline) kết hợp dịch thuật ngữ nghĩa, mở rộng từ vựng, phân loại độ khó CEFR và sinh câu ví dụ có điều kiện theo đúng trình độ người học yêu cầu.

2.2. Phát biểu bài toán Học Máy (Task Formulation)

ĐẦU VÀO (INPUT)

- Từ/cụm từ tiếng Việt (≤ 3 tokens: "tốt", "quả táo", "thất vọng")
- Cấp độ CEFR mục tiêu: $target_level \in \{A1, A2, B1, B2, C1\}$

ĐẦU RA (OUTPUT)

- Từ tiếng Anh chuẩn xác nghĩa & đạt đúng CEFR mục tiêu.
- Câu ví dụ hoàn chỉnh chứa từ khóa, đạt đúng CEFR kiểm chứng.
- Cờ kiểm định: $target_match, needs_review, meaning_analysis$.

Vì sao bài toán bắt buộc cần Machine Learning?

- Dịch ngữ cảnh & Đa nghĩa:** Đòi hỏi khả năng tổng quát hóa từ dữ liệu song ngữ, không thể dùng bảng tra 1-1 đơn giản.
- Đánh giá độ phức tạp CEFR:** Là hàm phi tuyến phức tạp kết hợp giữa độ dài, tần suất từ, độ sâu cú pháp và phân phối từ loại.
- Sinh ngôn ngữ có điều kiện (Controlled Generation):** Đòi hỏi mô hình Seq2Seq có khả năng khái quát hóa và thỏa mãn đồng thời ràng buộc từ vựng (lexical) và mức độ CEFR.

3. Kiến Trúc Pipeline & Các Họ Mô Hình (Multi-Family ML)

⚡ SƠ ĐỒ LƯỚI XỬ LÝ ĐA TẦNG (END-TO-END PIPELINE)

STAGE 1

Neural Translation & Semantic Expansion

Seq2Seq Transformer

MarianMT (Vi→En) sinh candidates → Mở rộng WordNet → Multilingual E5 Embeddings lọc và loại bỏ candidate sai lệch ngữ nghĩa.

STAGE 2

Word-Level CEFR Difficulty Estimator

Linear / Logistic Regression

Phân loại cấp độ CEFR từ vựng dựa trên độ dài, tần suất sử dụng, độ phức tạp hình thái & đối chiếu từ điển chuẩn hóa Lemma+POS.

STAGE 3

Controlled Example Sentence Generator

Pre-trained Seq2Seq (FLAN-T5)

Sinh câu ví dụ tự nhiên hoàn chỉnh có điều kiện: bắt buộc chứa từ vựng mục tiêu và thỏa mãn cấu trúc ngữ pháp mức CEFR yêu cầu.

STAGE 4

Sentence-Level CEFR Verification

Ensemble Tree (Random Forest)

Trích xuất đặc trưng cú pháp, phân phối POS, chỉ số đọc hiểu (FKGL) để thẩm định độc lập câu sinh ra có đạt đúng CEFR mục tiêu hay không.

Chi tiết các phân hệ mô hình học máy:

- 1. Mô hình Dịch & Mở rộng ngữ nghĩa (Model 1)** `MarianMT` `E5 Embeddings` : Được fine-tune trên dữ liệu song ngữ Việt-Anh, kết hợp từ điển song ngữ AVDict và WordNet. Cơ chế Semantics-First sử dụng `multilingual-e5` để kiểm định độ tương đồng ngữ nghĩa, triệt tiêu hiện tượng trôi nghĩa (semantic drift).
- 2. Mô hình Ước lượng CEFR Từ vựng (Model 2a)** `Logistic Regression` : Phân loại mức độ khó của từ vựng (A1-C1) dựa trên đặc trưng hình thái học và tần suất thống kê, kết hợp xác thực chính xác theo chuẩn lemma + POS.
- 3. Mô hình Sinh câu ví dụ có ràng buộc (Model 3a)** `FLAN-T5-small` : Mô hình sinh ngôn ngữ có kiểm soát, nhận prompt chứa từ khóa và CEFR target để tạo ra câu ví dụ tự nhiên, đúng ngữ pháp và bao hàm từ vựng yêu cầu.
- 4. Mô hình Thẩm định độ khó câu ví dụ (Model 2b)** `Random Forest Classifier` : Bộ phân loại đa lớp sử dụng tập đặc trưng ngôn ngữ chuyên sâu (Lexical diversity, syntactic depth, POS distribution, Flesch-Kincaid) để kiểm chứng độc lập mức độ CEFR của câu sinh ra.
- 5. Cơ chế Human-in-the-loop & Quality Gate**: Áp dụng ngưỡng tin cậy (Confidence thresholding) để tự động gắn cờ `needs_review: true` đối với các mẫu dự đoán có độ tin cậy thấp, phục vụ giám sát và kiểm duyệt bởi giáo viên/người học.

4. Điểm Nổi Bật & Giá Trị Đóng Góp Của Đề Tài

💡 Nguyên tắc Semantics-First

Bảo toàn tuyệt đối ngữ nghĩa gốc tiếng Việt trước khi lọc CEFR; không bao giờ vì ép chuẩn độ khó mà chọn từ sai lệch ngữ cảnh.

🌲 Kết hợp Đa dạng Họ Mô hình

Kết hợp nhuần nhuyễn giữa Classical ML (Logistic Regression, Random Forest với Feature Engineering) và Deep Learning (MarianMT, FLAN-T5, E5).

📊 Chuẩn mực Nghiên cứu ML

Mọi mô hình đều được tự huấn luyện, fine-tune và đánh giá định lượng bằng các metric tiêu chuẩn (SacreBLEU, ROUGE-L, SARI, Macro F1, FKGL).

🚀 Khả năng Đóng gói & Triển khai

Toàn bộ pipeline sẵn sàng phục vụ qua REST API (FastAPI) và Web UI trực quan, tối ưu hóa tốc độ thực thi trên cả CPU và GPU CUDA.